CLIMATESCOPE · 项目文档

ClimateScope 项目企划书

全球陆地—海洋月度温度异常的可复现数据平台

版本 v1.2 | 2026-10-30 | 当前阶段：数据管道、数仓、统计分析与多 horizon 回测已完成

文档范围：项目背景 · 数据资产 · 系统架构 · 数仓设计 · 技术选型
实施计划 · 质量与风险 · 验收标准

目录

0. 摘要 3

1. 项目背景 3

2. 项目目标与范围 4

3. 数据资产 5

4. 系统架构 6

5. 数据仓库设计 7

6. 技术选型 9

7. 工程实现与复现 10

8. 分析与建模 11

9. 可视化与交互规划 13

10. 里程碑与交付物 14

11. 风险与应对 14

12. 验收标准 14

附录 A：数据字典摘要 15

附录 B：术语表 15

0. 摘要

ClimateScope（项目代号 CLMTA）是一个面向月度全球气候指标的数据平台。项目以 NOAA 公开的全球陆地—海洋温度异常数据为基础，建设可复现的数据管道和 DuckDB 数仓，并已完成统计分析与多 horizon 预测回测；后续将加入协变量、可视化和可选的对话式查询能力。

当前阶段已经完成：

- 三条月度序列的自动获取、校验、原始快照和元数据记录；
- DuckDB `raw → staging → marts` 三层数仓；
- STL、年度 Mann-Kendall、Theil-Sen、变点、热力图和海陆对比；
- 9 个 origin × h=1/3/6/12/24 的多 horizon 预测，以及按 horizon 的区间覆盖率；
- 数据字典、示例 SQL 和 18 个自动化测试；
- `make data`、`make db`、`make query`、`make test`、`make analyze`、`make forecast` 六个可复现命令。

后续阶段将围绕“先理解数据、再评估模型、最后做展示”的顺序推进。项目不会在数据和分析结果尚未验证时预先给出模型指标。

1. 项目背景

1.1 研究对象

项目研究的核心指标是全球陆地—海洋平均温度异常（temperature anomaly）：某个月的平均气温相对于 1901–2000 年同期平均值的偏差，单位为 °C。

例如，`202609, 1.33` 表示 2026 年 9 月全球陆地与海洋的平均气温比 1901–2000 年 9 月平均高 1.33 °C。

1.2 为什么做这个项目

- 数据时间跨度长：1850-01 至 2026-09，共 2,121 个月，适合练习趋势、季节性、变点和极值分析；
- 数据公开可获取：NOAA NCEI Climate at a Glance 提供稳定的 CSV 接口；
- 数据可验证：原始快照、sha256、行数、时间范围和基准期都可以记录；
- 结构清晰：三条序列（全球陆海、陆地、海洋）可以支撑对比分析，也为后续加入半球和纬度带留出空间。

1.3 数据特点与挑战

特点	对项目的影响
温度异常有正有负	负值表示比基准期更冷，不是绝对温度，也不是“零下”
早期海洋观测稀疏	1880 年以前不确定性更大，图表和结论需要标注
2026 年只有 1–9 月	年度对比时必须排除不完整年份
官方会修订历史值	需要保留原始快照和每次更新的元数据
全球均值掩盖区域差异	后续需要补充陆地/海洋、半球和纬度带序列

2. 项目目标与范围

2.1 总体目标

建设一个可复现、可追溯、可扩展的月度气候数据平台：

1. 一条命令更新数据，一条命令重建数仓；
2. 每个数据文件都有来源、哈希和时间范围；
3. 数据质量问题在入库前被拦截；
4. 后续分析和预测都基于同一份可信数据。

2.2 分阶段目标

阶段	内容	状态
1. 数据管道 + 数仓	数据获取、校验、raw 快照、metadata、DuckDB 三层	已完成
2. 统计分析	STL、年度 Mann-Kendall、变点、热力图、海陆对比	已完成
3. 预测基准	多 horizon 回测、候选模型、误差与区间评估	已完成（多 horizon）
4. 可视化	Streamlit 数据概览、趋势、模型对比、查询	规划中
5. 对话式查询	只读工具调用、数据来源标注、评测	可选

2.3 当前范围（In scope）

- 三条 NOAA 月度序列：`land_ocean`、`land`、`ocean`；
- 1850-01 至最新可用月份；
- 数据校验、原始快照、元数据、DuckDB 数仓；
- 数据字典、示例查询、自动化测试；
- 为统计分析和预测预留接口。

2.4 明确不做（Out of scope）

- 不做绝对气温重建或气候模式模拟；
- 不做网格化气象场、区域降尺度或 CMIP 数据处理；
- 不把全球均值结论直接用于气候政策判断；
- 当前阶段不引入 Spark、Kafka、Flink、K8s 等分布式组件；
- 当前阶段不训练深度学习模型，先完成统计分析和可解释基线。

3. 数据资产

3.1 数据来源

序列	来源	频率 / 范围	用途
`land_ocean`	NOAA NCEI Climate at a Glance	月，1850–2026-09	主序列
`land`	NOAA NCEI Climate at a Glance	月，1850–2026-09	陆地对比
`ocean`	NOAA NCEI Climate at a Glance	月，1850–2026-09	海洋对比

- 基准期：1901–2000
- 单位：°C
- 数据许可：美国政府作品，公有领域，使用时需注明 NOAA 来源
- 官方入口：NOAA Climate at a Glance

3.2 关键数据事实

以下统计均针对全球陆海主序列（`land_ocean`）。

项目	数值
时间范围	1850-01 ~ 2026-09
每条序列记录数	2,121
三条序列总记录数	6,363
数值范围	−0.66 ~ 1.40 °C
2025 年均值	1.12 °C
2026 年 1–9 月均值	1.17 °C
最新月份（2026-09）	1.33 °C
有记录以来最暖月份	2023-09（1.40 °C）
1970–2026 线性趋势	约 +0.196 °C / 十年
2020–2026 年均值	1.06 °C

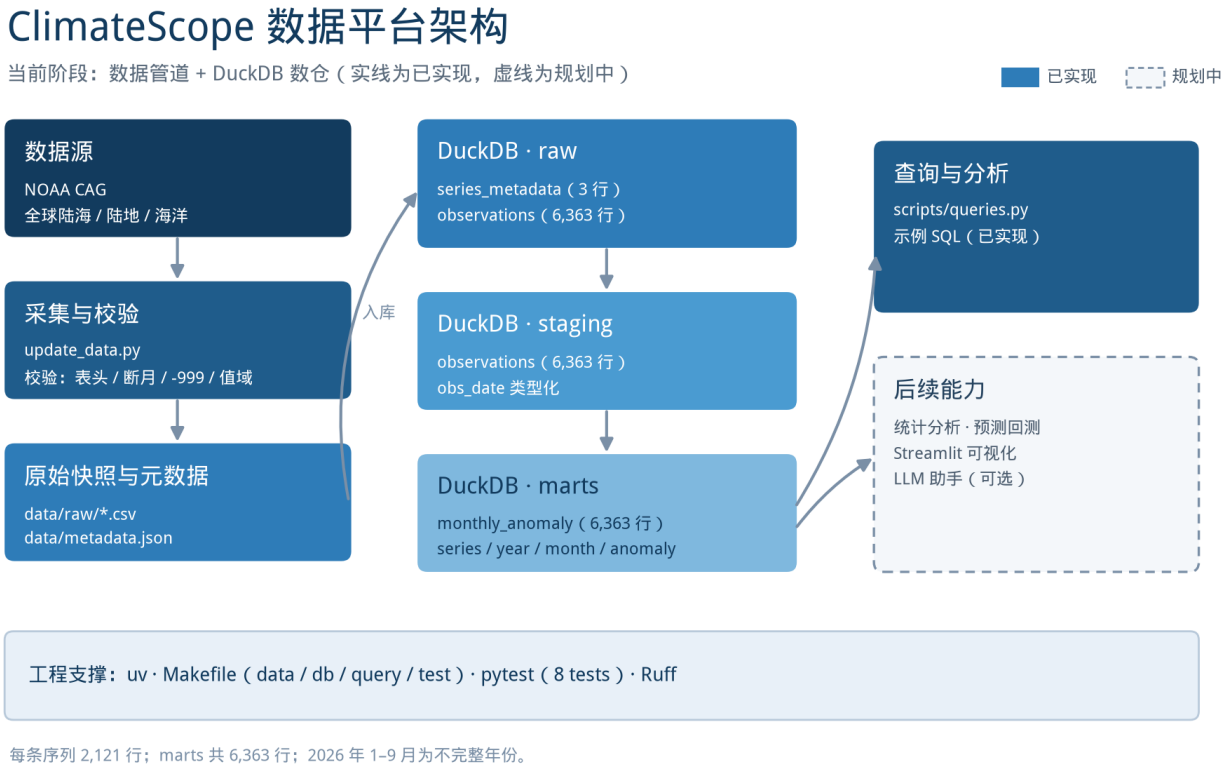
3.3 数据文件与元数据

文件	说明
`data/data.csv`	全球陆海主序列（`Date, Anomaly`）
`data/land.csv`	全球陆地序列
`data/ocean.csv`	全球海洋序列
`data/metadata.json`	每条序列的 sha256、行数、时间范围、来源 URL、原始文件名
`data/raw/`	NOAA 原始快照，只增不删

3.4 使用注意

- 温度异常不是绝对温度；
- 1880 年以前海洋覆盖稀疏，早期结果需要更谨慎；
- 2026 年只有 9 个月，年度排名应排除；
- NOAA 可能回改历史值，因此保留 raw 快照和 metadata；
- 全球均值不能替代区域分析。

4. 系统架构



ClimateScope 数据平台架构

4.1 分层说明

层	组件	产出
数据源	NOAA CAG（三条序列）	原始 CSV
采集与校验	`scripts/update_data.py`	raw 快照、`metadata.json`、标准 CSV
数仓	DuckDB `raw / staging / marts`	可查询的分层数据
查询与分析	`scripts/queries.py`、后续分析模块	SQL 结果、图表、报告
应用	Streamlit、可选的 LLM 助手	交互式页面、对话式查询

4.2 数据流

```
NOAA CAG
  → update_data.py（下载 / 校验 / 快照 / metadata）
  → data/raw/*.csv + data/metadata.json
  → DuckDB raw.observations + raw.series_metadata
  → staging.observations（生成 obs_date）
  → marts.monthly_anomaly（补充 year / month）
  → queries.py / 后续分析 / 可视化
```

4.3 工程支撑

- `uv`：环境与依赖管理；
- `Makefile`：`data` / `db` / `query` / `analyze` / `forecast` / `test` / `pipeline`；
- `pytest`：18 个测试，覆盖数据解析、错误分支、数仓构建、预测指标和趋势检验；
- `Ruff`：代码规范检查；
- `DuckDB`：单文件数仓，无需额外服务。

5. 数据仓库设计

5.1 分层与表

层	表	粒度	行数	说明
raw	`raw.series_metadata`	每条序列一行	3	来源、sha256、行数、时间范围、原始文件名
raw	`raw.observations`	序列 × 月	6,363	直接读取原始 NOAA 快照
staging	`staging.observations`	序列 × 月	6,363	生成 `obs_date`，统一类型
marts	`marts.monthly_anomaly`	序列 × 月	6,363	分析主表，含 `year`、`month`、`anomaly`

5.2 字段摘要

表	关键字段
`raw.series_metadata`	`series`、`sha256`、`row_count`、`first_month`、`last_month`、`base_period`、`source_url`、`raw_file`
`raw.observations`	`series`、`date_int`（YYYYMM）、`anomaly`、`source_file`
`staging.observations`	`series`、`date_int`、`obs_date`（DATE）、`anomaly`、`source_file`
`marts.monthly_anomaly`	`series`、`date_int`、`obs_date`、`year`、`month`、`anomaly`

完整字段类型和说明见 `docs/data_dictionary.md`。

5.3 数据质量规则

入库前检查：

- 基准期是否为 1901–2000；
- 按固定列名解析 CSV，并统一为 `Date` / `Anomaly`；
- 日期是否为 `YYYYMM`，月份是否合法；
- 行数是否足够，起始月份是否为 1850-01；
- 数值能否转成浮点数，是否落在合理范围；
- 是否混入 `-999`；
- 是否断月、重复、倒序；
- 数据是否过旧；
- 新数据是否比旧数据更旧（防回退）。

数仓构建后检查：

- `raw` / `staging` / `marts` 三层行数一致；
- 每条序列行数与 metadata 一致；
- `obs_date`、`anomaly` 无空值；
- 起止月份与 metadata 一致；
- 构建失败自动回滚。

5.4 示例查询

```
-- 最近 3 个月全球陆海温度异常
SELECT date_int, anomaly
FROM marts.monthly_anomaly
WHERE series = 'land_ocean'
ORDER BY obs_date DESC
LIMIT 3;

-- 最热年份 Top 5（只统计 12 个月的完整年份）
SELECT year, ROUND(AVG(anomaly), 2) AS avg_anomaly
FROM marts.monthly_anomaly
WHERE series = 'land_ocean'
GROUP BY year
HAVING COUNT(*) = 12
ORDER BY avg_anomaly DESC
LIMIT 5;

-- 2015–2024 年陆地 vs 海洋
SELECT series, ROUND(AVG(anomaly), 2) AS avg_anomaly
FROM marts.monthly_anomaly
WHERE year BETWEEN 2015 AND 2024
  AND series IN ('land', 'ocean')
GROUP BY series
ORDER BY series;
```

6. 技术选型

层	当前	后续规划	理由
语言 / 环境	Python 3.12 + uv	保持	依赖可复现，环境启动快
数据获取	requests	保持	接口简单，标准 CSV
数据处理	pandas	pandas + DuckDB	小数据足够，SQL 便于分析
数仓	DuckDB	保持	单文件、零运维、列式查询
统计	—	statsmodels、scipy、ruptures	STL、趋势检验、变点
机器学习	—	LightGBM	小数据上训练快、可解释
基础模型	—	Chronos-Bolt（零样本）	CPU 可跑，作为对照
可视化	—	Streamlit + Plotly	快速构建交互页面
测试 / 规范	pytest、Ruff	保持	最低成本的工程保障

6.1 选型原则

- 数据量小，优先单机方案；
- 先保证可复现，再追求复杂度；

- 统计基线优先于复杂模型；
- 每个技术选择都要能解释“为什么不用更重的方案”。

6.2 明确不引入

- Kafka、Spark、Flink、K8s；
- 微服务和多数据库拆分；
- 当前阶段的深度学习训练；
- 未经验证的大模型微调。

7. 工程实现与复现

7.1 目录结构

```
CLMTA/
├── data/
│   ├── data.csv / land.csv / ocean.csv
│   ├── metadata.json
│   ├── clmta.duckdb
│   └── raw/
├── docs/
│   ├── data_dictionary.md
│   ├── architecture-data.png
│   └── 项目企划书
├── scripts/
│   ├── update_data.py
│   ├── build_db.py
│   └── queries.py
├── src/
├── tests/
├── Makefile
├── README.md
└── pyproject.toml
```

7.2 常用命令

命令	作用
`uv sync`	同步依赖和环境
`make data`	从 NOAA 更新数据、raw 快照和 metadata
`make db`	重建 DuckDB `raw → staging → marts`
`make query`	运行示例 SQL
`make analyze`	生成 STL、趋势、变点、热力图和海陆对比
`make forecast`	运行 9 个 origin 的多 horizon 预测并保存指标
`make test`	Ruff + pytest
`make pipeline`	`make data` + `make db`

7.3 测试与质量

当前测试覆盖：

- 正常数据通过校验；
- 断月数据报错；
- `-999` 数据报错；
- 数仓三层行数、序列数、空值、起止月份；
- 预测指标、特征构建和区间覆盖；
- Mann-Kendall、年度均值和不完整年份处理；
- 项目基本文件和依赖导入。

当前结果：18 个测试全部通过，Ruff 无错误。

8. 分析与建模

8.1 已完成的统计分析

- STL 分解：趋势、季节、残差；
- 年度均值与 120 个月滚动均值；
- 年度 Mann-Kendall 检验：S = 9428.0，Z = 12.062，p < 1e-16；
- Theil-Sen 斜率：0.0533 °C/十年，95% CI [0.0455, 0.0610]；
- 变点检测：pen=10 时变点为 1935、1980；pen=5/10/20 的敏感性已记录；
- 月度热力图：按年代 × 月份展示异常值；
- 海陆对比：120 个月滚动平均。

2026 年只有 1–9 月，年度趋势和变点分析默认排除该不完整年份。极值分析、连续暖月和季节差异分解尚未实现。

8.2 已完成的多 horizon 回测

口径：9 个 origin（2020-09 至 2024-09，每 6 个月一个），每个 origin 只用当时可见历史，分别预测 h=1、3、6、12、24 个月；窗口内不回填真实值。每个 horizon 有 9 个 origin 样本，窗口互相重叠，不是完全独立样本。

RMSE（°C）：

Horizon	Seasonal Naive	Drift	SARIMAX	LightGBM
1	0.2010	0.1201	0.0826	0.1144
3	0.2237	0.1138	0.1166	0.1673
6	0.2238	0.1672	0.2290	0.2659
12	0.2098	0.2066	0.2868	0.2688
24	0.2642	0.2508	0.3495	0.3198

MASE：

Horizon	Seasonal Naive	Drift	SARIMAX	LightGBM
1	1.2512	0.8239	0.5654	0.7581
3	1.3506	0.8049	0.8303	0.9997
6	1.3588	1.1707	1.5636	1.8316
12	1.2105	1.2432	1.9490	1.8449
24	1.8569	1.7270	2.4595	2.3292

SARIMAX 区间覆盖：

Horizon	80% 覆盖率	80% 宽度	95% 覆盖率	95% 宽度
1	1.0000	0.2407	1.0000	0.3680
3	1.0000	0.3633	1.0000	0.5556
6	0.7778	0.4306	0.8889	0.6585
12	0.4444	0.4661	0.8889	0.7128
24	0.3333	0.4722	0.6667	0.7222

结论：

- SARIMAX 仅在 h=1 最优（RMSE 0.0826，MASE 0.5654）；
- h=3 起 Drift 的 RMSE 更低；h=12 的 MASE 最低是 Seasonal Naive，h=24 的 MASE 最低是 Drift；
- SARIMAX 随 horizon 变长明显退化，长期预测不占优；
- SARIMAX 区间在 h=1–3 过宽，在 h=12–24 过窄（80% 覆盖率 0.444/0.333），区间校准随 horizon 恶化；
- LightGBM 是按 horizon 分别训练的直接多步模型，不是递归预测。

8.3 年度口径

2026 年只有 1–9 月。年度排名和年度均值必须使用完整年份：

```
GROUP BY year
HAVING COUNT(*) = 12
```

或者在分析前显式过滤 `year <= 2025`。

8.4 后续建模计划

- 增加更多 origin 或非重叠窗口，降低样本相关性；
- 接入 CO_2 / ONI 协变量，尝试 SARIMAX-X；
- 引入 Chronos 等基础模型作为对照；
- 补充极值、连续暖月和季节差异分析；
- 将指标、预测和检验结果统一落盘，便于复现。

9. 可视化与交互规划

9.1 Streamlit 页面

- 数据概览：最新月份、年度均值、序列对比；
- 趋势与分解：STL、滚动均值、变点；
- 模型对比：不同 horizon 的误差与区间；
- 数据表：按序列和年份筛选，支持下载。

9.2 对话式查询（可选）

在数据和分析接口稳定后，可以增加只读工具调用：

- 查询指定序列和时间范围；
- 计算趋势、对比两个时期；
- 调用预测结果；
- 回答必须带数据来源和基准期；
- 用固定问题集评估工具调用和拒答行为。

该能力为可选项，不影响当前数据管道和数仓的交付。

10. 里程碑与交付物

阶段	完成标准	状态
1. 数据管道 + 数仓	`make data` / `make db` 可复现；三层行数一致；18 tests 通过	已完成
2. 统计分析	STL、年度 Mann-Kendall、Theil-Sen、变点、热力图、海陆对比	已完成
3. 预测基准	9 个 origin × h=1/3/6/12/24 + 误差/覆盖报告	已完成（多 horizon）
4. 可视化	Streamlit 四页 + 本地运行	规划中
5. 对话式查询	只读工具 + 小规模评测	可选

10.1 交付物

- 可复现的数据管道和 DuckDB 数仓；
- 数据字典和 README；
- 示例 SQL 与自动化测试；
- STL、热力图、海陆对比和预测对比图；
- `forecast_horizon_metrics.csv`、`forecast_horizon_predictions.csv` 和 `analysis_summary.json`；
- 后续的多 horizon benchmark 和可视化页面。

11. 风险与应对

风险	应对
NOAA 修订历史数据	保留 raw 快照、metadata、sha256；构建前做防回退校验
早期观测稀疏	图表和结论标注 1880 年前的不确定性
2026 年数据不完整	年度统计使用 `HAVING COUNT(*) = 12`
网络或接口不可用	下载失败时中止，不覆盖旧数据；保留上一次快照
范围膨胀	按阶段推进；当前阶段不引入分布式组件和深度模型
生成物与源码不一致	`make db` 可重复构建；数据字典记录表结构
数据库文件较大	单文件 DuckDB，必要时可通过 `make db` 重建

12. 验收标准

12.1 当前阶段

- `make data` 能更新三条序列、raw 快照和 metadata；

- `make db` 能构建 `raw` / `staging` / `marts`，三层各 6,363 行；
- `make query` 能返回最近月份、完整年份 Top 5、2015–2024 海陆对比；
- `make analyze` 能生成 STL、趋势、变点、热力图和海陆对比；
- `make forecast` 能生成多 horizon 指标、预测文件和误差/覆盖图；
- `make test` 通过 Ruff 和 18 个 pytest 用例；
- 数据字典和 README 与代码一致。

12.2 后续阶段

- 统计分析报告包含方法、图表和限制说明；
- 预测报告包含多 horizon 回测、基线对比和区间覆盖率；
- 可视化页面能按序列和时间范围交互；
- 所有结论都能追溯到数据版本和 SQL/代码。

附录 A：数据字典摘要

完整数据字典见 `docs/data_dictionary.md`。

表	主要字段
`raw.series_metadata`	series、sha256、row_count、first_month、last_month、base_period、source_url、raw_file
`raw.observations`	series、date_int、anomaly、source_file
`staging.observations`	series、date_int、obs_date、anomaly、source_file
`marts.monthly_anomaly`	series、date_int、obs_date、year、month、anomaly

附录 B：术语表

- 温度异常 / 距平：相对基准期的偏差，不是绝对温度。
- 基准期：本项目为 1901–2000 年。
- raw / staging / marts：原始层、类型化层、分析层。
- MASE：平均绝对误差除以季节性朴素基线的平均绝对误差。
- CRPS：连续排名概率得分，评估概率预测。
- rolling origin：滚动起点回测，避免未来信息泄漏。